



Universidade Estadual do Piauí – *campus* Parnaíba
Curso Superior de Tecnologia em Sistemas de Computação
Disciplina: Fundamentos em Inteligência Artificial
Docente: Prof. Dr. Dario Brito Calçada

Desafio Cerebral: Redes Neurais Artificiais e Perceptron

Willamy Josué Santos Serejo

1. Explique o funcionamento do neurônio artificial.

O neurônio artificial funciona como uma função matemática que imita o comportamento de um neurônio biológico, composto por entradas, pesos, um somador e uma função de ativação. Tudo começa quando o neurônio recebe um conjunto de dados de entrada, em seguida cada entrada é multiplicada por um peso específico, que funciona como um indicador de importância, onde pesos maiores dão mais relevância à entrada, enquanto pesos menores ou negativos reduzem seu impacto. Em seguida, o neurônio realiza uma junção somadora, calculando a soma de todos os produtos das entradas por seus respectivos pesos e adicionando a esse total um valor constante chamado bias, que serve para ajustar a sensibilidade do neurônio. O resultado dessa soma é então passado para uma função de ativação, que decide qual resposta o neurônio deve "disparar". Essa função introduz uma propriedade não-linear ao sistema, permitindo que ele aprenda padrões complexos e gerando a saída final, que pode ser o resultado definitivo do modelo ou a entrada para os próximos neurônios da rede.

2. Descreva os objetivos principais das funções de ativação.

O objetivo principal de uma função de ativação é quebrar a linearidade dos dados. Ao apenas multiplicar as entradas pelos pesos e somar tudo, o neurônio estará fazendo um cálculo puramente linear, uma equação de reta. A função de ativação entra justamente para distorcer essa reta, permitindo que a rede neural consiga desenhar curvas e superfícies complexas para aprender a separar ou classificar esses dados. Outro ponto é o controle do fluxo e da escala dessas informações. A soma matemática dentro do neurônio pode gerar números gigantescos ou excessivamente negativos, o que causaria um colapso nos cálculos do computador. A função de ativação atua como um regulador de dados, pegando qualquer valor infinito e espremendo-o dentro de um intervalo civilizado e padronizado, como por exemplo o intervalo entre 0 e 1.

3. Faça uma analogia entre os elementos constituintes do neurônio artificial e do neurônio biológico.

Cada elemento computacional foi criado para reproduzir uma função do neurônio biológico. Os dendritos, responsáveis por receber sinais de outras células, correspondem às entradas do sistema. As sinapses, que determinam a intensidade desses sinais, são representadas pelos pesos, indicando a importância de cada entrada. No corpo celular, os estímulos são integrados; no modelo artificial, essa função é realizada pela junção somadora, que multiplica as entradas pelos pesos, soma os resultados e adiciona o bias. Em seguida, a função de ativação decide se o neurônio deve gerar uma resposta, simulando o limiar de ativação biológico. Por fim, o axônio, que transmite o impulso nervoso para outras células, corresponde à saída do neurônio artificial, responsável por enviar o resultado do processamento.

4. Discorra sobre a importância envolvendo o limiar de ativação.

O limiar de ativação é a barreira que determina se um neurônio deve ou não disparar um sinal. Ele funciona como uma chave liga-desliga baseada em intensidade: se o estímulo recebido pelo neurônio for fraco e ficar abaixo desse limite, ele é completamente ignorado e a saída é zero; se o estímulo atingir ou ultrapassar esse valor determinado, o neurônio é ativado e passa a informação adiante. Sua importância está em garantir a estabilidade e a seletividade do sistema. Ao impor um teto mínimo para o disparo, o limiar de ativação atua como um filtro, impedindo que qualquer dado irrelevante provoque reações em cadeia desnecessárias.

5. Em relação as características das redes neurais artificiais, explique em que consiste a adaptação por experiência e a capacidade de generalização.

A adaptação por experiência consiste na habilidade da rede neural de aprender e se moldar a partir dos dados que lhe são apresentados, sem a necessidade de regras ou fórmulas previamente digitadas. A cada erro cometido diante de um dado, os algoritmos matemáticos calculam o desvio e sintonizam a rede, fazendo com que ela se adapte e melhore seu desempenho conforme acumula "experiência" com aquela base de dados. A capacidade de generalização, por sua vez, é o objetivo final desse aprendizado e consiste na habilidade da rede neural de aplicar o conhecimento adquirido com a experiência para resolver situações inéditas. Assim, quando o sistema finalizado é exposto a dados novos, que ele nunca viu durante a fase de treinamento, ele consegue fazer previsões, classificações ou diagnósticos corretos com base no comportamento geral que aprendeu a reconhecer no passado.

6. Discorra sobre as principais características matemáticas que são verificadas nas funções de ativação logística e tangente hiperbólica.

Não-Linearidade e Continuidade: Ambas introduzem não-linearidade ao modelo, permitindo o aprendizado de padrões complexos. São funções contínuas e infinitamente diferenciáveis em todo o seu domínio, o que viabiliza o cálculo exato de derivadas exigido pelo algoritmo de retropropagação (backpropagation).

Limitação de Amplitude (Saturação): Atuam como funções de esmagamento (squashing), restringindo valores infinitos a intervalos previsíveis. A função Logística comprime a saída no intervalo entre 0 e 1, sendo amplamente

utilizada para predição de probabilidades. Já a Tangente Hiperbólica restringe os dados entre -1 e 1.

Simetria e Centralização (Zero-Centered): A principal vantagem da Tangente Hiperbólica sobre a Logística é ser perfeitamente simétrica em relação à origem (centrada no zero). Isso faz com que a média das saídas dos neurônios seja próxima de zero, normalizando os dados para as camadas seguintes e acelerando a convergência do treinamento, enquanto a Logística pode introduzir vieses sistemáticos por gerar apenas valores positivos.

Saturação e Desvanecimento do Gradiente: Ambas compartilham a limitação matemática de saturar em suas extremidades. Quando a entrada assume valores muito altos ou muito baixos, a derivada da função aproxima-se de zero. No treinamento de redes profundas, isso causa o desvanecimento do gradiente (vanishing gradient), onde o sinal do erro desaparece e interrompe o aprendizado das primeiras camadas.

7. Obtenha as expressões analíticas das derivadas de primeira ordem da função de ativação logística e tangente hiperbólica.

A função tangente hiperbólica é dada por:	$f(x) = \tanh(x)$	A função de ativação logística.	$f(x) = \frac{1}{1 + e^{-x}}$
Sua derivada de primeira ordem é:	$f'(x) = 1 - f^2(x)$	Sua derivada de primeira ordem é:	$f'(x) = f(x)(1 - f(x))$

8. Para um problema específico, há a possibilidade de utilizar como função de ativação tanto a função logística como a tangente hiperbólica. Em termos de implementação em hardware, discorra quais seriam os eventuais aspectos relevantes para seleção de uma dessas.

Em termos de implementação em hardware, aspectos como complexidade do circuito, consumo de energia, velocidade de processamento e representação numérica devem ser considerados na escolha entre a função logística e a tangente hiperbólica. A função logística produz saídas entre 0 e 1, enquanto a tangente hiperbólica gera valores entre -1 e 1, o que pode ser vantajoso em arquiteturas que utilizam representação em complemento de dois, por ser simétrica em torno de zero. Além disso, ambas podem ser implementadas por aproximações matemáticas ou algoritmos como o CORDIC, porém a complexidade e o custo de hardware dependem da técnica utilizada. Dessa forma, a escolha deve levar em conta o equilíbrio entre precisão, área ocupada no chip, consumo energético e desempenho exigido pela aplicação.

9. Considerando que as operações individuais nos neurônios artificiais são realizados mais rapidamente em comparação com neurônios biológicos, explique porque diversas atividades executadas pelo cérebro humano produzem resultados mais rapidamente que um microcomputador.

Embora os neurônios artificiais realizem operações individuais muito mais rapidamente que os neurônios biológicos, o cérebro humano consegue executar diversas tarefas em menor tempo devido ao seu elevado grau de paralelismo. Enquanto um microcomputador tradicional processa grande parte das instruções de forma sequencial, o cérebro possui bilhões de neurônios interconectados operando simultaneamente e trocando informações em paralelo. Dessa forma, atividades como reconhecimento de padrões, processamento de imagens, fala e tomada de decisões podem ser realizadas de maneira extremamente eficiente, compensando a menor velocidade individual dos neurônios biológicos. Além disso, o cérebro apresenta grande capacidade de adaptação e processamento distribuído, o que contribui para seu alto desempenho em tarefas complexas.

10. Quais os principais tipos de problemas em que redes neurais artificiais são aplicadas?

As redes neurais artificiais são aplicadas principalmente em problemas de classificação, regressão, reconhecimento de padrões, previsão e séries temporais, agrupamento de dados (clustering), processamento de imagens e sinais, reconhecimento de fala, processamento de linguagem natural, detecção de anomalias e sistemas de apoio à decisão. Elas são especialmente úteis em situações em que existem grandes volumes de dados e relações complexas entre as variáveis, tornando difícil a construção de modelos baseados em regras explícitas. Dessa forma, as redes neurais conseguem aprender a partir de exemplos e generalizar o conhecimento adquirido para resolver novos problemas.

11. Discorra sobre as vantagens e desvantagens envolvidas na aprendizagem usando lote de padrões e aprendizagem usando padrão-por-padrão.

Na aprendizagem usando lote de padrões (batch learning), os pesos da rede neural são atualizados somente após a apresentação de todos os exemplos do conjunto de treinamento. Como vantagem, esse método produz atualizações mais estáveis, reduzindo oscilações e tornando o processo de convergência mais suave. Além disso, o gradiente calculado representa melhor o comportamento global dos dados. Como desvantagem, exige maior quantidade de

memória e processamento, além de responder mais lentamente a mudanças nos dados.

Já na aprendizagem padrão-por-padrão (online ou incremental), os pesos são atualizados após a apresentação de cada exemplo de treinamento. Sua principal vantagem é a rapidez nas atualizações, menor necessidade de memória e maior capacidade de adaptação a dados que mudam ao longo do tempo. Por outro lado, as atualizações podem ser mais instáveis, gerando oscilações durante o treinamento e tornando a convergência menos suave quando comparada ao método em lote. Portanto, a escolha entre os dois métodos depende do tipo de aplicação, da quantidade de dados disponível e dos requisitos de desempenho e adaptação da rede neural.

12. Considere uma aplicação que possua quatro entradas e duas saídas. O projetista menciona que neste caso a rede feedforward de camadas múltiplas a ser implementada deve conter necessariamente quatro neurônios na primeira camada. Discorra se tal informação é pertinente.

A afirmação não é necessariamente pertinente. Em uma rede feedforward de múltiplas camadas com quatro entradas e duas saídas, é obrigatório que a camada de entrada possua quatro entradas (ou unidades de entrada) para receber as variáveis do problema. Entretanto, isso não significa que a primeira camada de neurônios da rede deva conter exatamente quatro neurônios. O número de neurônios nas camadas ocultas é um parâmetro de projeto que depende da complexidade do problema, da quantidade de dados disponíveis e do desempenho desejado. Assim, uma rede com quatro entradas pode ter qualquer quantidade adequada de neurônios nas camadas ocultas, enquanto a camada de saída deverá possuir dois neurônios para representar as duas saídas da aplicação. Portanto, o fato de existirem quatro entradas não obriga a existência de quatro neurônios na primeira camada da rede.

13. Em relação ao exercício anterior, cite alguns fatores que influenciam na determinação do número de camadas escondidas de uma rede feedforward de camadas múltiplas.

A determinação do número de camadas escondidas em uma rede feedforward de múltiplas camadas depende de diversos fatores. Entre os principais estão a complexidade do problema a ser resolvido, o grau de não linearidade dos dados, a quantidade e qualidade dos dados de treinamento, o nível de precisão desejado, a capacidade de generalização da rede e os recursos computacionais disponíveis. Problemas mais simples podem ser resolvidos com uma única camada escondida, enquanto problemas mais complexos podem exigir múltiplas camadas para extrair características e representar relações mais elaboradas entre as entradas e saídas. Além disso, o número de camadas deve ser escolhido de forma a evitar tanto o subajuste (underfitting) quanto o sobreajuste (overfitting), buscando um equilíbrio entre desempenho e complexidade do modelo.


14. Quais as eventuais diferenças estruturais observadas nas redes com arquitetura recorrente em relação àquelas com arquitetura feedforward?

As redes neurais com arquitetura recorrente diferem das redes feedforward principalmente pela presença de conexões de realimentação (feedback). Nas redes feedforward, a informação flui apenas em uma direção, da camada de entrada para as camadas ocultas e, posteriormente, para a camada de saída, sem retornar a neurônios anteriores. Já nas redes recorrentes existem conexões que permitem que a saída de um neurônio ou camada seja utilizada novamente como entrada em instantes posteriores, criando ciclos na rede. Essa característica fornece uma forma de memória interna, permitindo que informações de estados anteriores influenciem o processamento atual. Por isso, redes recorrentes são especialmente adequadas para problemas que envolvem sequências temporais, como reconhecimento de fala, processamento de linguagem natural e previsão de séries temporais, enquanto redes feedforward são mais indicadas para problemas estáticos de classificação e regressão.

15. Mencione em que tipos de aplicações é essencial a utilização de redes neurais recorrentes.

As redes neurais recorrentes são essenciais em aplicações que envolvem dados sequenciais ou temporais, nas quais informações passadas influenciam as decisões futuras. Entre os principais exemplos estão o reconhecimento e síntese de fala, o processamento de linguagem natural (tradução automática, chatbots e análise de texto), a previsão de séries temporais (como demanda de energia, mercado financeiro e clima), a detecção de padrões em sinais, o controle de processos dinâmicos e a análise de vídeos e sequências de eventos. Nessas aplicações, a capacidade da rede recorrente de armazenar informações sobre estados anteriores é fundamental para modelar dependências temporais e produzir resultados mais precisos do que arquiteturas feedforward convencionais.

16. Elabore um diagrama de blocos que ilustre o funcionamento do treinamento supervisionado.



17. Discorra sobre o conceito de método de treinamento e algoritmo de aprendizado, explicitando-se ainda o conceito de época de treinamento.

O método de treinamento corresponde à forma como os padrões de treinamento são apresentados à rede neural e como os pesos são atualizados durante o aprendizado. Os principais métodos são o treinamento em lote (batch), no qual os pesos são ajustados após a apresentação de todo o conjunto de treinamento, e o treinamento padrão-por-padrão (online ou incremental), em que os pesos são atualizados após cada exemplo apresentado. Já o algoritmo de aprendizado é o procedimento matemático utilizado para calcular os ajustes necessários nos pesos da rede com base no erro obtido, buscando minimizar a diferença entre a saída produzida e a saída desejada. Exemplos de algoritmos de aprendizado incluem a regra de Hebb, o algoritmo Perceptron e o Backpropagation. Por sua vez, uma época de treinamento corresponde a um ciclo completo de apresentação de todos os padrões do conjunto de treinamento à rede neural. Normalmente, várias épocas são necessárias para que a rede aprenda adequadamente e atinja um nível de erro aceitável.

18. Quais as principais diferenças existentes entre métodos baseados em treinamento supervisionado e não-supervisionado?

A principal diferença entre os métodos de treinamento supervisionado e não supervisionado está na disponibilidade de saídas desejadas. No treinamento supervisionado, a rede aprende a partir de exemplos rotulados, comparando sua saída com a saída esperada para ajustar os pesos. Já no treinamento não supervisionado, não existem rótulos ou respostas corretas; a rede aprende identificando padrões, similaridades ou agrupamentos presentes nos dados de entrada. Enquanto o treinamento supervisionado é usado principalmente para classificação e previsão, o não supervisionado é frequentemente aplicado em tarefas de agrupamento e descoberta de padrões.


19. Considere uma aplicação específica, explicita então como poderia ser um critério de desempenho utilizado para ajustes de pesos e limiares da rede que empregará método de treinamento com reforço.

No treinamento por reforço, os ajustes dos pesos e limiares são realizados com base em um critério de desempenho fornecido pelo ambiente. Um critério possível é a recompensa obtida pela rede ao executar uma ação. Se a ação produzir um resultado desejado, a rede recebe uma recompensa positiva e reforça os pesos envolvidos; caso contrário, recebe uma penalização, levando à correção dos pesos e limiares. Assim, o objetivo é maximizar a recompensa acumulada ao longo do treinamento.

20. Explique como se processa a regra de Hebb. No contexto do algoritmo de aprendizado Perceptron.

A regra de Hebb estabelece que o peso de uma conexão deve ser aumentado quando a entrada e a saída associada são ativadas simultaneamente. No Perceptron, isso significa que, quando um padrão é apresentado e a resposta desejada é positiva, os pesos das entradas ativas tendem a ser reforçados. Assim, entradas que contribuem para uma resposta correta têm seus pesos aumentados, fortalecendo a associação entre o estímulo de entrada e a resposta produzida pela rede.

21. Mostre por intermédio de gráficos ilustrativos como pode ocorrer a instabilidade no processo de convergência do Perceptron quando da utilização de valores inapropriados para a taxa de aprendizado.



Quando a taxa de aprendizado assume valores muito elevados, os ajustes realizados nos pesos tornam-se excessivos. Como consequência, o erro não diminui de forma gradual, passando a oscilar em torno da solução ótima sem convergir. O gráfico ilustra essa situação, mostrando que, ao longo das épocas de treinamento, o erro apresenta sucessivas oscilações, caracterizando a instabilidade do processo de convergência do Perceptron.

22. Explique por que o Perceptron só consegue classificar padrões cuja fronteira de separação entre classes seja linear.

O Perceptron consegue classificar apenas padrões linearmente separáveis porque sua saída é determinada por uma combinação linear das entradas seguida de uma função de ativação. Dessa forma, a fronteira de decisão gerada pela rede corresponde a uma reta (em duas dimensões), um plano (em três dimensões) ou um hiperplano (em dimensões maiores). Quando as classes podem ser separadas por essa fronteira linear, o algoritmo converge para uma solução. Entretanto, se os padrões apresentarem uma separação não linear, como no problema XOR, não existe uma única reta ou hiperplano capaz de separar corretamente todas as amostras, tornando impossível a classificação correta pelo Perceptron de camada única.

23.Em termos de implementação computacional descreva a importância de tratarmos o limiar de ativação (θ) como um dos elementos do vetor de pesos (w).

Em termos de implementação computacional, tratar o limiar de ativação (θ) como um dos elementos do vetor de pesos simplifica os cálculos e a implementação dos algoritmos de treinamento. Para isso, adiciona-se uma entrada com valor fixo (bias), associada a um peso correspondente ao limiar. Além de simplificar o código, essa abordagem permite que o limiar seja ajustado automaticamente pelo mesmo algoritmo utilizado para atualizar os demais pesos da rede.

24.Seja um problema de classificação de padrões que se desconhece a priori se as duas classes são ou não separáveis linearmente. Elabore uma estratégia para verificar a possível aplicação Perceptron em tal problema.

Uma estratégia consiste em treinar um Perceptron com os padrões disponíveis e observar o comportamento do erro durante o treinamento. Se o algoritmo convergir após um número finito de épocas, atingindo erro nulo ou aceitável, pode-se concluir que as classes são linearmente separáveis e que o Perceptron é adequado para o problema. Por outro lado, se o treinamento não convergir e o erro permanecer oscilando mesmo após muitas épocas, isso indica que as classes provavelmente não são linearmente separáveis, tornando necessária a utilização de uma rede mais complexa, como um Perceptron de múltiplas camadas.

25.Dois projetistas de instituições diferentes estão aplicando uma rede Perceptron para mapear o mesmo problema de classificação de padrões. Discorra se é correto afirmar que ambas as redes convergirão com o mesmo número de épocas.

Não, não é correto afirmar que ambas as redes convergirão com o mesmo número de épocas. Embora estejam resolvendo o mesmo problema e utilizem o mesmo modelo Perceptron, o número de épocas necessárias para a convergência pode variar devido a diversos fatores, como os valores iniciais dos pesos, a taxa de aprendizado adotada, a ordem de apresentação dos padrões de treinamento e os critérios de parada utilizados. Assim, mesmo que ambas as redes encontrem uma solução correta para um problema linearmente separável, elas podem convergir em quantidades diferentes de épocas.

26.Em relação ao exercício anterior, considere-se que ambas as redes já estão devidamente treinadas. Para um conjunto contendo 10 novas amostras que devem ser identificadas, explique se os resultados produzidos por ambas serão os mesmos.

Sim, caso os dados usados para resolver o problema sejam o mesmo. Embora os treinamentos possam resultar em pesos finais e números de épocas diferentes, se as redes foram treinadas com os mesmos dados e para o mesmo problema de classificação, ambas apresentarão os mesmos resultados.


27.Seja um problema de classificação de padrões que seja linearmente separável composto de 50 amostras. Em determinada época de treinamento observou-se que somente para uma dessas amostras a rede não estava produzindo a resposta desejada. Discorra se é então necessário apresentar novamente todas as 50 amostras na próxima época de treinamento.

Sim. Em uma nova época de treinamento é necessário apresentar novamente todas as 50 amostras à rede. Uma época corresponde justamente à apresentação completa de todo o conjunto de treinamento. Além disso, a correção realizada para a única amostra classificada incorretamente altera os pesos da rede, podendo afetar a classificação de amostras que anteriormente estavam corretas. Portanto, é necessário reapresentar todos os padrões para verificar se a rede continua classificando corretamente todo o conjunto de dados e, assim, garantir a convergência do treinamento.

28.Considere um problema de classificação de padrões composto de duas entradas $\{x_1$ e $x_2\}$., cujo conjunto treinamento é composto pelas seguintes amostras de treinamento:

x_1	x_2	Classe
0,75	0,75	A
0,75	0,25	B
0,25	0,75	B
0,25	0,25	A

Mostre se é possível aplicar Perceptron na resolução deste problema.



Como os pontos da classe A e da classe B ocupam posições diagonais opostas, não existe uma reta capaz de separá-los completamente. Portanto, o problema não é linearmente separável e não pode ser resolvido por um Perceptron de camada única.

29. Explique de forma detalhada quais seriam as eventuais limitações do Perceptron se considerarmos o seu limiar de ativação nulo.

Se o Perceptron possuir limiar de ativação nulo ($\theta = 0$), a fronteira de decisão ficará restrita a passar obrigatoriamente pela origem do sistema de coordenadas. Isso reduz a flexibilidade da rede para separar classes, pois nem todos os problemas linearmente separáveis possuem uma reta, plano ou hiperplano de separação que passe pela origem. Dessa forma, alguns problemas que poderiam ser resolvidos por um Perceptron com limiar ajustável tornam-se impossíveis de classificar corretamente quando o limiar é fixado em zero. Além disso, a rede perde um grau de liberdade importante no processo de aprendizado, diminuindo sua capacidade de adaptação aos dados e podendo resultar em menor desempenho na classificação de padrões. Por esse motivo, normalmente o limiar é tratado como um parâmetro treinável (bias), permitindo deslocar a fronteira de decisão para a posição mais adequada no espaço de características.

Projeto Prático

Pela análise do processo de destilação fracionada do petróleo observou-se que determinado óleo poderia ser classificado em duas classes de pureza (P1 e P2)

Utilizando o algoritmo supervisionado de Hebb para classificação de padrões, e assumindo-se a taxa de aprendizagem como 0,01, faça as seguintes atividades:

Execute 5 treinamentos para a rede Perceptron, iniciando-se os vetores de pesos (w) em cada treinamento com valores aleatórios entre zero e um.

Registre os resultados dos cinco treinamentos em uma tabela contendo:

- Pesos iniciais
- Pesos finais
- Número de épocas

Treinamento	Pesos iniciais (w_1)	Pesos iniciais (w_2)	Pesos iniciais (w_3)	Pesos finais (w_1)	Pesos finais (w_2)	Pesos finais (w_3)	Número épocas
1º(T1)	0.2999	0.6426	0.9617	1.5671	2.4816	-0.7339	423
2º(T2)	0.1275	0.7364	0.6161	1.4141	2.4342	-0.7031	350
3º(T3)	0.9643	0.9897	0.699	1.4355	2.4121	-0.6797	356
4º(T4)	0.2075	0.9532	0.0712	1.5604	2.4587	-0.7291	381
5º(T5)	0.4993	0.3630	0.4021	1.5647	2.4687	-0.7337	396

Após o treinamento do Perceptron, coloque o mesmo em operação, aplicando-o na classificação automática das amostras conforme a tabela a seguir:

Legenda: P1 = -1 e P2 = 1

Amostra	x1	x2	x3	y(T1)	y(T2)	y(T3)	y(T4)	y(T5)
1	-0,3665	0,0620	5,9891	P1	P1	P1	P1	P1
2	-0,7842	1,1267	5,5912	P2	P2	P2	P2	P2
3	0,3012	0,5611	5,8234	P2	P2	P2	P2	P2

4	0,7757	1,0648	8,0677	P2	P2	P2	P2	P2
5	0,1570	0,8028	6,3040	P2	P2	P2	P2	P2
6	-0,7014	1,0316	3,6005	P2	P2	P2	P2	P2
7	0,3748	0,1536	6,1537	P1	P1	P1	P1	P1
8	-0,6920	0,9404	4,4058	P2	P2	P2	P2	P2
9	-1,3970	0,7141	4,9263	P1	P1	P1	P1	P1
10	-1,8842	-0,2805	1,2548	P1	P1	P1	P1	P1